



Аналитическая система для эпидемиологического мониторинга COVID-19 на основе метаданных рентгеновских снимков, используя стек PySpark.

Разработал: Барышев В.В.

Структура работы

1. Архитектура решения;
2. Ключевые статистики;
3. Визуализации и выводы

```
project/  
├── analysis.ipynb  
├── presentation.pdf  
├── README.md  
└── requirements.txt
```

Ссылка на репозиторий:

<https://github.com/vbaryshev/spark>

Архитектура решения

1. Источники данных

- Вход: медицинские снимки (DICOM / PNG) + таблица метаданных (пациент, дата, нормализованный диагноз, локализация).
- Метаданные связаны со снимками и могут использоваться как дополнительные признаки.

2. Подготовка данных

- Фильтрация снимков по качеству и наличию корректной разметки.
- Нормализация диагнозов (diagnosis_norm), очистка редких/шумных значений.
- Разбиение на train / valid / test по пациентам (исключение утечки между выборками).

3. Обработка изображений

- Приведение всех снимков к единому размеру (ресайз).
- Нормализация интенсивностей (масштабирование, выравнивание распределения).
- Аугментации для увеличения объема и разнообразия данных (отражения, повороты, изменение яркости, шум и т.п.).

Общая схема, см. рисунок 1

Подготовка данных для анализа мед. снимков



Рисунок 1. Общая схема.

Ключевые статистики

Объём данных

- 472 пациента, 472 рентген-снимка грудной клетки.
- 4 уникальных диагноза (класса): COVID-19, Pneumonia, Normal, Other.
- Средний возраст пациентов ≈ 54 года (диапазон 18–94 лет).

Баланс классов

- Распределение по диагнозам:
 - COVID-19 — 312 снимков ($\approx 66\%$)
 - Pneumonia — 112 ($\approx 24\%$)
 - Other — 37 ($\approx 8\%$)
 - Normal — 11 ($\approx 2\%$)
- Перекос классов: датасет сильно доминирует классом COVID-19.
- Редкие классы (если считать редкими <20 наблюдений): Normal — 11 снимков ($\approx 2.3\%$ выборки).

Разметка и location (view)

- Распределение снимков по view:
 - PA — 149 ($\approx 31.6\%$)
 - AP — 140 ($\approx 29.7\%$)
 - AP Supine — 98 ($\approx 20.8\%$)
 - L — 51 ($\approx 10.8\%$)
 - Axial — 33 ($\approx 7.0\%$)
 - AP Erect — 1 ($\approx 0.2\%$)
- В среднем диагнозов:
 - на пациента: ≈ 1.0 ($312+112+37+11$ пациентов при таком же числе исследований);
 - на снимок: 1 диагноз (один целевой класс на одно исследование).
- Замечание по полу (для ключевых классов):
 - COVID-19: 56% мужчин, 32% женщин, 11% без указания пола; Pneumonia: 54% мужчин, 38% женщин, 8% без указания пола.

Визуализация и выводы

Общий вывод:

На основании проведённого анализа можно сделать вывод, что исходный датасет обладает существенными ограничениями для построения надёжной и хорошо обобщающей модели.

Небольшой объём данных в сочетании с сильным дисбалансом классов (особенно крайней редкостью класса Normal) приводит к риску смещения модели в сторону доминирующего класса и затрудняет адекватную оценку качества по редким классам. Разнообразие проекций усложняет задачу и требует либо нормализации по видам укладок, либо явного учёта view как дополнительного признака.

Наконец, несбалансированное гендерное распределение и наличие пропусков по полу ограничивают обобщаемость результатов на более широкую популяцию. Для практического применения модели на реальных данных целесообразно: расширить датасет (особенно за счёт классов Normal и недопредставленных состояний), использовать методы борьбы с дисбалансом и продуманно контролировать влияние различий в проекциях и демографических характеристиках

Рисунок 2. Распределение диагнозов.




Рисунок 2. Количество исследований.




Рисунок 3. Распределение по возрастным группам.



Рисунок 4. Распределение диагнозов(локация).

